Тема проекта: Выявление морфометрических маркеров психических заболеваний по данным МРТ методами биостатистики и машинного обучения.

Объект исследования: Морфометрические параметры головного мозга (1000+ признаков) выборки из 517 пациентов с верифицированными психиатрическими диагнозами при наличии опорной подгруппы, состоящей из здоровых пациентов.

Дано: медицинские морфометрические данные МРТ-исследований порядка 500 пациентов, здоровых и больных различными психическими заболеваниями. Измерения проводились в двух группах: UCLA (272 пациента) и TCP (245 пациентов). На каждого пациента произведены многочисленные типовые замеры различных участков мозга. Замеры хранятся в различных таблицах Excel, упорядоченные по кодовому имени пациента и названию участка мозга. Одни и те же измерения делаются для нескольких участков мозга одного пациента, поэтому данные разбиты на таблицы с неоднородной структурой. Всего таблицы насчитывают более 1000 измерений на каждого пациента. Коды заболеваний и клинико-демографические данные прилагаются отдельно для каждого пациента.

Найти: различные статистические зависимости между данными цифрами и типом заболевания, чтобы облегчить постановку диагноза путём прогноза заболевания на основании морфометрических данных.

План работы:

ЭТАП 1. Предобработка данных

1. Извлечь данные из таблиц Excel и отформатировать их в формате JSON со следующей структурой:

```
код_пациента: {
    site: "UCLA" / "TCP",
    morphometry: {
        тип_исследования: {
            код_зоны_мозга: {
                код_подзоны_мозга: {
                    наименование_параметра: значение, ...
                }, ...
            }, ...
        }, ...
    },
    demographics: {
        наименование_параметра: значение, ...
    },
    disease: код заболевания
}, ...
```

   можно сгенерировать код парсера или написать парсер CSV файлов самостоятельно.

2. Перевести данные в единую таблицу, где строка — уникальный код пациента, столбцы — морфометрические параметры (признаки) и код заболевания (целевая переменная). Результат сохранить в формате CSV.

ВНИМАНИЕ: Не допускать перемешивания измерений разного вида в одном столбце! При отсутствии данного типа измерений для данной зоны, заполнить столбец значениями NaN. Каждый столбец должен строго содержать только измерения одного типа одной подзоны или зоны. Схлопывание столбцов из-за отсутствия данных недопустимо.

3. Перевести данные в набор тензоров. Поскольку некоторые измерения записаны в виде [зона-подзона-измерение], другие в виде [зона-объём подзоны], а третьи в виде [объём зоны] сложить все данные в один тензор не получится. Нужно представить все данные в виде нескольких тензоров со структурой вроде:

```
[500 Пациентов]
      |
      ├── ТЕНЗОР А (3D): [500 × Уникальные_Подзоны × Физические_Замеры]
      |     Смысл: Толщина, площадь и кривизна коры для КАЖДОЙ микроподзоны.
      |
      ├── МАТРИЦА Б (2D): [500 × Уникальные_Подзоны]
      |     Смысл: Чистые объемы (в мм³) анатомических микросегментов.
      |
      ├── МАТРИЦА В (2D): [500 × Общие_Макрозоны]
      |     Смысл: Интегральные объемы крупных долей мозга (для макроанализа).
      |
      └── ТАБЛИЦА Г (2D): [500 × Клинико_Демографические_Фичи]
            Смысл: Пол, возраст + Целевой класс (Код заболевания / Норма).
```


```
[500 Пациентов]
      |
      ├── ТЕНЗОР А (3D): [500 × Уникальные_Подзоны × Физические_Замеры]
      |     Смысл: Толщина, площадь и кривизна коры для КАЖДОЙ микроподзоны.
      |
      ├── МАТРИЦА Б (2D): [500 × Уникальные_Подзоны]
      |     Смысл: Чистые объемы (в мм³) анатомических микросегментов.
      |
      ├── МАТРИЦА В (2D): [500 × Общие_Макрозоны]
      |     Смысл: Интегральные объемы крупных долей мозга (для макроанализа).
      |
      └── ТАБЛИЦА Г (2D): [500 × Клинико_Демографические_Фичи]
            Смысл: Пол, возраст + Целевой класс (Код заболевания / Норма).
```


Сохранить данные в виде Python-тензоров NPZ.

ВНИМАНИЕ: Поскольку каждая зона содержит разный набор подзон, невозможно выделить зону в отдельную размерность. Мы используем только уникальные подзоны каждой зоны в качестве размерности, при этом упуская информацию о зоне.

ВНИМАНИЕ: Не допускать перемешивания измерений разного вида в разных столбцах. При отсутствии данного типа измерений для данной подзоны, заполнить столбец значениями NaN. Не допускать «схлопывания» столбцов и смешивания смысла цифр в одной размерности.

4. **Тщательно проверить качество извлечения данных:**
    a. Проверить отсутствие дубликатов кодов пациентов (автоматически)
    b. Проверить наличие аномальных значений (отрицательных, 9999 и пр.)
    c. Провести выборочную ручную сверку 5% записей с оригинальными Excel.

5. **Анализ пропусков, аномальных дефектов (выбросов) и структурных дефектов**:
    a. Оценить долю пропущенных значений для каждого признака.
    b. Если потребуется, применить методы заполнения пропусков (медиана, KNN-импутация). Отдельно сохранить оригинальные данные и данные с заполнениями.
    c. Оценить процентное распределение пропущенных значений (`NaN`) по каждому столбцу. Признаки с критическим уровнем разреженности (более 5%) изолировать. Реализовать сравнительный пайплайн: сохранить оригинальную разреженную матрицу для этапа биостатистики и заполненную матрицу (с применением медианной импутации или алгоритма *KNNImputer*) для последующего ИИ-моделирования.
    d. Реализовать поиск выбросов с помощью межквартильного размаха (IQR) и метода Isolation Forest. Выбросы на МРТ случаются из-за движений пациента, например, сглотнул слюну, а цифра улетела в потолок или обнулилась.
        i. Метод IQR предполагает рисование диаграммы «ящик с усами». Ящик – это 50% центральных значений. Усы – это по 1.5-3.0 длины ящика вверх и вниз. Значения, которые выпали за границы «усов» (обычно не более 1%) считаются выбросами и требуют особого внимания или фильтрации.
        ii. Метод Isolation Forest ищет аномалии по совокупности признаков. Он строит случайные деревья решений, пытаясь «изолировать» каждого пациента от остальных. Если пациента удается отделить от группы всего за 2–3 ветвления дерева, значит, его комбинация признаков уникальна и аномальна. Такой пациент требует ручной проверки данных.
        iii. Провести ручной аудит подсвеченных пациентов для разделения истинного технического брака (ошибки сегментации, опечатки) от тяжелых форм биологической патологии. Удалению подлежат исключительно верифицированные технические артефакты.
    e. **Произвести статистический анализ на предмет возможного случайного перемешивания данных разного типа в одном столбце**. Убедиться, что каждый столбец содержит только измерения одного типа одной зоны. При перемешивании возникнет статистическое раздвоение (бимодальность).
        i. Для каждого столбца рассчитать коэффициент бимодальности Сарле и провести дип-тест Хартигана на унимодальность.
            1. **Коэффициент бимодальности Сарле (Sarle's Bimodality Coefficient)**: Простой математический маркер. Если он превышает порог 5/9 ≈ 0.55, распределение гарантированно имеет несколько пиков.
            2. **Индекс дип-теста Хартигана (Hartigan's Dip Test)**: Официальный статистический критерий для проверки гипотезы об унимодальности (однопиковости). Если p-value теста меньше 0.05, значит, в столбце сидит смесь данных (несколько пиков).

P-value любого теста – это площадь отрезанного «хвоста» (или двух хвостов) канонического распределения данного теста, который начинается от значения данного теста на данной выборке и уходит в область еще более экстремальных значений. Если данный тест выдал значение, отрезающее хвост площадью меньше 0.05 (аномалия), то принято считать данный тест положительным. Под «каноническим распределением» здесь понимается распределение нулевой гипотезы (H_0). То есть это вероятностное распределение значений теста, которое мы бы получили, если бы в данных не было никакого эффекта (всё случайно).

Данное «каноническое распределение» считается на всех возможных выборках, не имеющих данного признака. Математики представляют это так: где-то в идеальном мире существует гигантская «генеральная совокупность» (например, абсолютно все люди на планете или бесконечный генератор случайных чисел). Из неё мы можем бесконечно выдергивать случайные выборки по 100 человек. В 99% этих случайных пар выборок никакого «признака» не будет — они будут похожи друг на друга, но из-за случайности значения теста на них будет слегка колебаться. Вот это колебание значения теста на случайных выборках и моделируется распределением «нулевой гипотезы» (т.е. плотность вероятности значений теста на случайных выборках). Далее на данной конкретной выборке считается тест, и его конкретное значение отрезает «хвост» (или хвосты) от распределения «нуль-гипотезы». Если площадь хвоста меньше 0.05 – тест положительный.

3. **Визуализация распределений:** Автоматическое построение графиков плотности (KDE, «сглаженная гистограмма», наложенная на гистограмму) для топ-50 признаков с наибольшим подозрением на бимодальность.

ii. При обнаружении статистического раздвоения (мультимодальности распределения, $p < 0.05$ в тесте Хартигана) изолировать признак для ручной проверки структуры исходных Excel-таблиц. Убедиться, что каждый столбец содержит измерения строго одного типа и одной анатомической зоны для всей выборки пациентов, исключив ложное расщепление смесей распределений.

6. **Межцентровая гармонизация данных (ComBat):** Ввиду присутствия в выборке данных с двух различных МРТ-сканеров (UCLA: 272 и TCP: 245), перед проведением биостатистики и обучения моделей ИИ применить алгоритм гармонизации ComBat (или NeuroComBat). Метод должен устранить системную межцентровую дисперсию (параметрический сдвиг средних значений и дисперсии, вызванный техническими характеристиками томографов), полностью сохранив при этом биологическую вариативность, ассоциированную с возрастом, полом и психическим заболеванием

ЭТАП 2. Разведочный анализ и биостатистика

Выполняется на выпрямленных плоских срезах данных с использованием опорной подгруппы в качестве референса. Это означает, что из многомерного тензора (п. 3, ЭТАП 1) делается одномерный срез по данному виду измерений, а вычисляемая величина считается для всех пациентов, а также отдельно по опорной группе здоровых людей и по каждой подгруппе больных с целью выяснения способности данного отдельно взятого измерения выделять данный вид заболевания.

Поиск потенциальных биомаркеров патологий выполняется строго через попарное сравнение клинических групп относительно референсной точки — опорной подгруппы условно здоровых пациентов. Смешивание различных нозологий (болезней) в один массив на этапе тестирования гипотез запрещено во избежание взаимного уничтожения разнонаправленных морфометрических сигналов.

1. **Описательная статистика:** Для количественных признаков рассчитать: меры центральной тенденции (среднее, медиана), меры рассеяния (стандартное отклонение, интерквартильный размах). Для номинальных признаков (пол, код исследовательской площадки UCLA/TCP, нозологическая группа) рассчитать абсолютные частоты (количество пациентов) и относительные доли (проценты).
2. **Проверка нормальности распределения**: Оценить характер распределения признаков с помощью критерия Шапиро-Уилка (или Колмогорова-Смирнова в модификации Лиллиефорса) по всем 517 объектам. В обязательном порядке построить квантильно-квантильные графики (Q-Q plots) и гистограммы с наложением кривых ядерной оценки плотности (KDE) для визуального контроля.
   В медицине на выборках в сотни объектов статистические тесты становятся «слишком чувствительными». Критерий Шапиро-Уилка может выдать $p < 0.05$ (формально распределение ненормально) из-за одного-единственного пациента-выброса. Посмотрев на Q-Q plot, вы сразу поймете реальную картину: если 499 точек лежат идеально на линии, а одна улетела в угол — данные нормальные, просто нужно изолировать этот один выброс.
3. **Попарное тестирование статистических гипотез**: Выявить параметры, значимо различающиеся между группами заболеваний по схеме: тест №1: «Здоровые пациенты vs Пациенты с Шизофренией»; тест №2: «Здоровые пациенты vs Пациенты с БАР»; тест №3: «Здоровые пациенты vs Пациенты с Депрессией» и т.д.:
   a. Использовать t-критерий Стьюдента или ANOVA (для признаков с нормальным распределением). При сравнении признака одновременно между тремя и более группами применять одномерный дисперсионный анализ (ANOVA).
   b. Использовать U-критерий Манна-Уитни или критерий Краскела-Уоллиса (для распределений, отличных от нормального).
4. **Контроль ложноположительных результатов (Множественное тестирование)**: Ввиду высокой размерности признакового пространства (1000+ тестов на каждую пару групп), для предотвращения накопления ошибки первого рода (ложных научных открытий) категорически запрещено использовать сырые значения p-value с базовым порогом 0.05.
   a. Студенты обязаны объединить все полученные p-value и применить процедуру контроля доли ложных отклонений Бенджамини-Хохберга (FDR).

b. Значимыми биомаркерами конкретного заболевания признавать только те анатомические структуры, у которых скорректированный показатель q-value строго меньше 0.05. Использование сверхконсервативной поправки Бонферрони исключить во избежание пропуска реальных слабовыраженных биомаркеров.

ЭТАП 3. Снижение размерности и корреляционный анализ

1. **Анализ мультиколлинеарности:** Рассчитать матрицу корреляции Спирмена (1000x1000). Исключить избыточные, сильно коррелирующие между собой морфометрические параметры ($r > 0.85$). Взять в рассмотрение только один параметр из тождественной пары.
2. **Визуализация и снижение размерности**. Применить методы:
    a. Сжатия признакового пространства PCA для снижения размерности (анализ главных компонент с сохранением 85% дисперсии, число компонент определяется автоматически scikit-learn по порогу сохранённой дисперсии)
    b. t-SNE / UMAP для визуализации структуры кластеров пациентов (отражение 1000-мерного пространства в 2-мерное с сохранением структуры кластеров). Визуальный тест. На вход алгоритма t-SNE (или UMAP) подавать строго матрицу главных компонент PCA, полученную на предыдущем шаге. Результат визуализировать в виде scatter-plot с цветовой разметкой точек по нозологиям и опорной подгруппе здоровых людей для визуальной оценки структуры кластеров.
3. **Генерация биомедицинских производных признаков (Feature Engineering):** На основе базовой морфометрии рассчитать относительные анатомические показатели (нормированные на общий объем серого вещества) и коэффициенты межполушарной асимметрии для ключевых ROI. Использовать LLM (ChatGPT/Claude) для генерации идей по математическому комбинированию признаков, специфичных для нейрорадиологии.
    a. **Относительные объемы:** Вычислить нормированные показатели, разделив локальные объемы подзон на общий объем серого вещества (поправка на индивидуальный размер черепа).
    b. **Коэффициенты асимметрии:** Рассчитать индексы межполушарной асимметрии парных структур по формуле: $\mathrm{AI} = (V_{\mathrm{left}} - V_{\mathrm{right}})/(V_{\mathrm{left}} + V_{\mathrm{right}})$
    c. **Использование LLM:** Использовать современные большие языковые модели (ChatGPT/Claude) на этапе генерации идей для математического комбинирования параметров, специфичных для дифференциальной психиатрической диагностики.
4. **Интерпретируемый Feature Engineering на основе главных компонент (PCA Loadings Analysis)**:
    a. Применить метод PCA для сжатия признакового пространства 1000+ параметров до уровня K главных компонент (базис определяется автоматически по порогу объясненной дисперсии ≥ 85%). Полностью заменить исходную матрицу признаков на матрицу латентных компонент.
    b. Провести дешифровку медицинского смысла первых 5–10 ключевых собственных векторов. Для этого проанализировать матрицу факторных нагрузок (Feature Loadings, таблица размером 1000 × K, где 1000 — исходные МРТ-параметры, а K — число выбранных главных компонент, например 30) и выделить топ-10 исходных МРТ-параметров с максимальными абсолютными весами для каждой компоненты.
    c. Дать содержательное клиническое описание (интерпретацию) каждому латентному вектору (например, «Индекс лобно-темпоральной деградации»,

«Индекс гиппокампальной асимметрии»), связав чистую математику PCA с нейроанатомией.

Сначала мы заставляем PCA извлечь «чистые» математические факторы из оригинальных МРТ-данных. Затем студенты вместе с LLM генерируют свои медицинские фичи (индексы). А на шаге 4 они смотрят через матрицу нагрузок, смог ли PCA сам, чисто математически, переоткрыть те самые индексы асимметрии и нормирования, которые человек придумал умозрительно. В научной практике такой подход называется валидацией латентных пространств с помощью априорных биологических гипотез.

ЭТАП 4. Прогностическое моделирование (Machine Learning)

1. **Постановка задачи:** Реализовать задачу многоклассовой классификации (прогноз типа заболевания по морфометрическому вектору). Разбить выборку на обучающую (Train) и тестовую (Test) в соотношении 80/20 с обязательной стратификацией по целевому классу.
2. **Обучение базовых классификаторов:** Оценить качество работы следующих моделей:
    a. **Регуляризованные линейные модели**: Обучить логистическую регрессию с штрафами Lasso (L_1) для агрессивного зануления неинформативных компонент (отбора признаков) и Ridge (L_2) для борьбы со скрытой мультиколлинеарностью.
    b. **Метод опорных векторов (SVM)**: Обучить классификатор SVM. Протестировать работу модели как с линейным ядром (Linear Kernel), так и с нелинейным радиально-базисным ядром (RBF Kernel) для поиска сложных геометрических разделяющих поверхностей в латентном пространстве.
    c. **Метод бэггинга (Случайный лес)**: Обучить модель Random Forest. Ограничить глубину деревьев для снижения риска оверфиттинга на выборке из 517 человек.
    d. **Ансамбли последовательного градиентного бустинга**: Обучить модели на основе деревьев решений, строящих цепочки предсказаний на остаточных ошибках градиента функций потерь. Провести сравнительный анализ трех ключевых библиотек: LightGBM, XGBoost и CatBoost.
    e. **Методологическое указание**: Особый фокус направить на CatBoost Classifier, так как данный алгоритм оптимизирован для работы со смешанными табличными биомедицинскими данными.
3. **Комплексная оценка метрик качества и кросс-валидация:** Сравнение моделей между собой проводить строго на этапе многоблочной стратифицированной кросс-валидации (Stratified K-Fold CV) на обучающей выборке, а финальное тестирование — на отложенных 20% данных.
    a. **Матрица ошибок (Confusion Matrix)**: Построить многоклассовые матрицы ошибок для визуализации векторов ложноположительных и ложноотрицательных прогнозов. Наглядно зафиксировать, какие диагнозы модели чаще всего путают между собой.
    b. **Анализ метрик в условиях возможного дисбаланса классов**: Категорически запрещено опираться на метрику Accuracy (общую точность) в качестве единственного критерия успеха. Базовое сравнение алгоритмов исследователи обязаны вести по пулу устойчивых метрик:
        i. **Balanced Accuracy** (сбалансированная точность, учитывающая объемы подгрупп).
        ii. **F1-macro** (среднее гармоническое точности и полноты, вычисляемое независимо для каждой болезни).

iii. **AUC-ROC** (Площадь под рок-кривой): Рассчитать многоклассовый показатель AUC-ROC методами One-vs-Rest (OvR) или One-vs-One (OvO) для оценки обобщающей способности моделей разделять распределения вероятностей классов.

ЭТАП 5. Нейросетевой анализ без учителя: Нормативное моделирование и поиск аномалий с применением вариационного автоэнкодера

1. **Нормативное моделирование на данных опорной подгруппы (β-VAE)**: Спроектировать и обучить ультра-легковесную архитектуру Вариационного автокодировщика (β-VAE). Обучение модели проводить строго на подвыборке условно здоровых пациентов (опорной подгруппе, (n approx 200). Сеть должна сформировать устойчивое вероятностное латентное пространство («узкое горлышко»), описывающее вариабельность здорового головного мозга.
2. **Критическая архитектурная спецификация (Микро-VAE)**: Для предотвращения переобучения (оверфиттинга) в условиях дефицита данных (Small Data DL) жестко ограничить глубину и размерность сети по следующей схеме:.

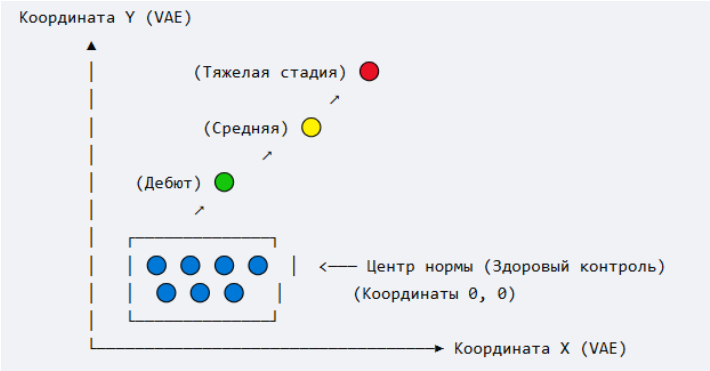
```
ВХОД СЕТИ:  [400 признаков МРТ]
                 |
СКРЫТЫЙ СЛОЙ 1: [64 нейрона]       <—— Это скрытый слой (промежуточный)
                 |
УЗКОЕ ГОРЛЫШКО: [ 2-4 нейрона ]       <—— Это БОТТЛНЕК / ЛАТЕНТНОЕ ПРОСТРАНСТВО
                 |
СКРЫТЫЙ СЛОЙ 2: [64 нейрона]       <—— Это снова скрытый слой (промежуточный)
                 |
ВЫХОД СЕТИ: [400 восстановленных признаков]
```


```
ВХОД СЕТИ:  [400 признаков МРТ]
                 |
СКРЫТЫЙ СЛОЙ 1: [64 нейрона]       <—— Это скрытый слой (промежуточный)
                 |
УЗКОЕ ГОРЛЫШКО: [ 2 нейрона ]       <—— Это БОТТЛНЕК / ЛАТЕНТНОЕ ПРОСТРАНСТВО
                 |
СКРЫТЫЙ СЛОЙ 2: [64 нейрона]       <—— Это снова скрытый слой (промежуточный)
                 |
ВЫХОД СЕТИ: [400 восстановленных признаков]
```


Студенты должны внедрить `Dropout` с коэффициентом 0.4–0.5 после каждого слоя и добавить L_2-регуляризацию (Weight Decay). Это заставит сеть при каждой итерации «забывать» половину связей, исключая заучивание конкретных 200 пациентов наизусть.

Дивергенция Кульбака-Лейблера: Использовать штрафной коэффициент beta > 1 для принудительного сжатия латентного пространства в стандартное нормальное распределение Гаусса.

3. **Выделение тенденций патологий:** Пропустить через обученный VAE профили пациентов с диагнозами, визуализируя траектории и непрерывные тенденции их отклонения от нормы в латентном пространстве.



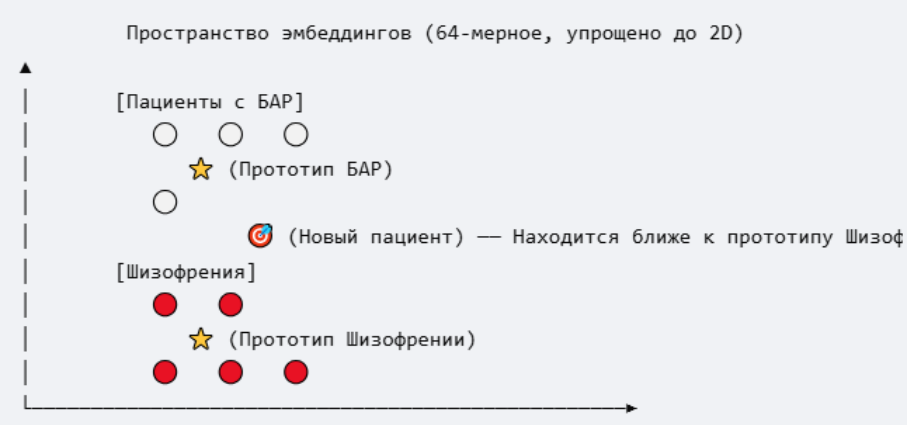
4. **Нейросетевая детекция аномалий и расчет индексов выраженности патологий:** Использовать обученный декодер beta-VAE как экспертную систему оценки структурных разрушений ткани мозга.
    a. Пропустить больных пациентов через полный цикл VAE (энкодер и декодер) и рассчитать индивидуальную ошибку реконструкции (Reconstruction Error) — математическую разницу между исходным МРТ-профилем и профилем, который сеть попыталась «подогнать» под здоровые шаблоны.
    b. Нормировать полученную ошибку восстановления в стандартизированный Z-score относительно распределения ошибок опорной подгруппы. Использовать данный показатель как объективную цифровую меру выраженности патологии и степени атипичности индивидуального МРТ-скана пациента для облегчения дифференциальной диагностики.

ЭТАП 6. Маловыборочное глубокое обучение нейросети с учителем (Few-Shot / Metric Deep Learning)

1. **Дизайн валидационного пайплайна:** Реализовать задачу многоклассовой классификации для предсказания конкретного нозологического кода заболевания или принадлежности пациента к опорной подгруппе здорового контроля.
    a. Разбиение выборки: Для получения несмещенной оценки обобщающей способности нейросети разделить объединенный мульти-тензорный датасет на обучающую (Train) и тестовую (Test) выборки в строгом соотношении 80/20.
    b. Ограничение: Ввиду ограниченного объема данных (n = 517) разделение векторов выполнять с обязательной стратификацией по целевым классам (Stratified Split) для сохранения идентичной пропорциональности клинических групп во всех подмножествах и исключения смещения предсказаний.
2. **Проектирование многовходовой прототипической нейросети (Multi-Input Prototypical Network):** Для преодоления «проклятия размерности» и эффективного обучения на малых выборках спроектировать нейросетевую архитектуру класса Few-Shot Learning, основанную на синергии принципов метрического обучения (метрика сходства сиамских сетей) и адаптивного резонанса Гроссберга (сравнение с эталонными шаблонами-прототипами).
    a. **Архитектура параллельных ветвей (Multi-Branch Input)**: Разработать три независимые параллельные суб-нейросети (энкодеры) для одновременной обработки разнородных признаковых пространств, сформированных на Этапе 1:
        i. **Ветвь А:** Принимает 3D-тензор физических замеров микроподзоны. Преобразует его через слои плотных отображений в латентный вектор.

ii. **Ветвь Б**: Принимает 2D-матрицу чистых объемов анатомических микросегментов. Преобразует в латентный вектор.
iii. **Ветвь В:** Принимает 2D-матрицу интегральных объемов крупных макрозон мозга. Преобразует в латентный вектор.

b. **Слияние признаков (Feature Fusion)**: На выходе из энкодеров произвести операцию конкатенции (склеивания) полученных векторов в единый монолитный многомерный эмбеддинг пациента.
c. **Вычисление прототипов и метрическое обучение**: На финальном слое в процессе обучения вычислять геометрические центроиды (средние векторы эмбеддингов) для каждой клинической группы — Прототипы классов. Сеть настраивается с помощью функции потерь Prototypical Loss так, чтобы минимизировать евклидово расстояние от индивидуального эмбеддинга пациента до прототипа его истинного класса и максимизировать до прототипов чужих классов. Классификация новых объектов выполняется по критерию минимального расстояния к центроиду патологии.



3. **Супрессия избыточности и жесткая регуляризация графа**: Учитывая высокий риск переобучения глубоких моделей на выборке из ~500 объектов, применить комплексную стратегию регуляризации весов:
    a. **Нейросетевой отбор признаков (L_1-Lasso)**: Внедрить во входные слои всех трех параллельных ветвей разреживающую L1-регуляризацию (L1 weight penalty). Это заставит алгоритм в процессе градиентного спуска принудительно занулять веса синапсов для неинформативных зон и параметров МРТ, выполняя автоматическую селекцию топ-маркеров.
    b. **Высококоэффициентный Dropout**: Установить агрессивный порог Dropout (0.5–0.6) после каждого скрытого слоя. Это заблокирует коадаптацию признаков и заучивание локального шума выборки.
4. **Межмодельный бенчмаркинг (Классический ML vs Deep Learning)**: Провести сравнительный анализ эффективности разработанной Few-Shot нейросети с результатами классического машинного обучения (п. 2, Этап 4).
    a. **Критерии сравнения**: Оценить, дает ли усложнение архитектуры до многовходовой метрической нейросети статистически значимый прирост качества классификации на малых данных по сравнению с самостоятельными алгоритмами последовательного бустинга (CatBoost) и бэггинга (Random Forest).

b. **Метрики валидации**: Сравнение вести строго по зафиксированному набору устойчивых метрик: Balanced Accuracy, F1-macro, AUC-ROC и по структуре ошибок в многоклассовых матрицах Confusion Matrix.

ЭТАП 7. Документирование и интерпретация результатов

1. Оформить код проекта в виде воспроизводимого репозитория (скрипты разметки + Jupyter Notebooks).
2. Выделить топ-15 наиболее значимых морфометрических признаков (Feature Importance) для каждого типа заболевания и сопоставить их с клиническими данными (ENIGMA).
    a. https://www.nature.com/articles/s41398-020-0705-1
    b. https://pmc.ncbi.nlm.nih.gov/articles/PMC4008818/
    c. https://pmc.ncbi.nlm.nih.gov/articles/PMC9098675/
    d. https://pmc.ncbi.nlm.nih.gov/articles/PMC8675422/
3. Рекомендуется использование LLM (ChatGPT/Claude) на этапе изучения технологии, генерации идей для Feature Engineering (создания производных признаков) и оптимизации гиперпараметров моделей.